数学 B　第 3 章　数学と社会生活

No.2　データにもとづく予測

月　　日　　名前

今日のゴール

- ☐ 散布図から、データを**近似する直線**を求められる
- ☐ データの変わり方を見て、**直線か曲線か**を選べる
- ☐ 予測を使うときの**注意点**（範囲の外・相関と因果）がわかる

1　近似する直線で予測する

数学 I で、2 つの変量の関係を散布図と相関係数で調べたね。散布図の点が直線のまわりに集まっているとき、その直線の式を求めれば、**まだ調べていない値を予測**できるんだ。

データを近似する直線（回帰直線）

n 組のデータ $(x_1,\ y_1),\ \cdots,\ (x_n,\ y_n)$ について、x、y の平均を $\overline{x}$、$\overline{y}$、x の分散を s_x^2、x と y の共分散を s_{xy} とすると、データにもっともよくあてはまる直線は

$$y = ax + b \qquad \text{ただし} \quad a = \frac{s_{xy}}{s_x^2},\quad b = \overline{y} - a\overline{x} \qquad (s_x^2 > 0)$$

各点と直線との「縦のずれ」の 2 乗の和がいちばん小さくなる直線なんだ（**最小二乗法**）。直線は必ず平均の点 $(\overline{x},\ \overline{y})$ を通るよ。x の値がすべて等しい（$s_x^2 = 0$）ときは使えないね。

例題 1　ある商品の売上 y（万個）は、発売から x 年目に右の表のようだった。データを近似する直線を求め、7 年目の売上を予測してみよう。

x	1	2	3	4	5
y	2	4	5	7	7

考え方・解き方

$\overline{x} = 3$、$\overline{y} = 5$。偏差は　$x - \overline{x}:\ -2,\ -1,\ 0,\ 1,\ 2$、　$y - \overline{y}:\ -3,\ -1,\ 0,\ 2,\ 2$

$$s_x^2 = \frac{4+1+0+1+4}{5} = 2,\quad s_{xy} = \frac{6+1+0+2+4}{5} = 2.6$$

$$a = \frac{2.6}{2} = 1.3,\quad b = 5 - 1.3 \times 3 = 1.1 \quad \text{よって} \quad y = 1.3x + 1.1$$

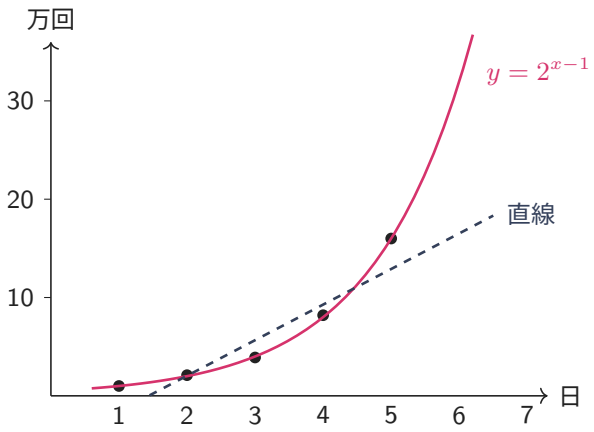
7 年目は　$1.3 \times 7 + 1.1 = 10.2$　より、**約 10.2 万個**と予測できる。

練習 1　ある店の来店客数 y（百人）は、x 週目に次の表のようだった。データを近似する直線を求め、8 週目の来店客数を予測してみよう。

x	1	2	3	4	5
y	10	12	15	15	18

2 直線か曲線か

データがいつも直線にそって変わるとは限らないよ。**差**が一定に近いなら直線（1 次関数）、**比**が一定に近いなら指数関数（等比数列）で近似するのが自然なんだ。



例題 2　ある動画の再生回数（万回）は、公開から 1 日目〜5 日目に 1, 2.1, 3.9, 8.2, 16 だった。このデータは直線と曲線のどちらで近似するのがよいか。また、7 日目の再生回数を予測してみよう。

考え方・解き方

となりとの差は 1.1, 1.8, 4.3, 7.8 で、どんどん大きくなる。一方、比はどれもほぼ 2 だね。

だから、**毎日約 2 倍**と考えて、**指数関数** $y = 2^{x-1}$ で近似するのがよい。

7 日目は　$2^6 = 64$　より、**約 64 万回**と予測できる。

直線で近似すると 7 日目は約 20 万回になって、予測が大きくちがうね。どの関数を選ぶかは、とても大事なんだ。

3 予測を使うときの注意

予測の注意点

- **データの範囲の外**ほど、予測は当たりにくい。同じ変わり方が続くとは限らない
- **相関があっても因果関係があるとは限らない**。別の変量（**第 3 の変数**）が両方に影響していることがある

例題 2 の再生回数も、毎日 2 倍がずっと続けば、30 日目には 2^{29} 万回、つまり約 5 兆回という現実ばなれした回数になってしまう。どこかで増え方はにぶるはずだね。

練習 2　次の問いに答えてみよう。

1 次のデータ (ア)、(イ) は、それぞれ直線と指数関数のどちらで近似するのがよいか。また、6 番目の値を予測しよう。

(ア) 3, 9, 27, 81, 243　　(イ) 5, 8, 11, 14, 17

2 ある地域では、アイスクリームの売上が多い日ほど、水の事故の件数が多いという正の相関があった。「アイスクリームを売ると水の事故が増える」と言えるか。理由とともに答えよう。

3 6 歳から 12 歳までの身長のデータから近似する直線を求め、40 歳の身長を予測した。この予測は信用できるか。理由とともに答えよう。

解答・解説

練習 1

$\overline{x}=3$、$\overline{y}=14$。偏差は　$x-\overline{x}:\ -2,\ -1,\ 0,\ 1,\ 2$、　$y-\overline{y}:\ -4,\ -2,\ 1,\ 1,\ 4$

$s_x^2=2$、　$s_{xy}=\dfrac{8+2+0+1+8}{5}=3.8$

$a=\dfrac{3.8}{2}=1.9$、　$b=14-1.9\times3=8.3$　よって $y=1.9x+8.3$

8 週目は　$1.9\times8+8.3=23.5$　より **約 2350 人**　（単位が百人だから 23.5 百人）

練習 2

1 (ア) 比がいつも 3 だから **指数関数**で近似。6 番目は $243\times3=$ **729**

(イ) 差がいつも 3 だから **直線**で近似。6 番目は $17+3=$ **20**

2 **言えない**。気温が高い日は、アイスクリームもよく売れるし、水遊びをする人も増える。**気温**という第 3 の変数が両方に影響していると考えられるから、相関があっても因果関係があるとは言えない。

3 **信用できない**。身長は成長期をすぎるとほとんど伸びなくなるから、データの範囲（6〜12 歳）の外の 40 歳まで同じ直線の変わり方が続くとは考えられない。

1 年に約 6 cm 伸びるとすると、40 歳で 3 m をこえてしまうね。